



## **Лабораторная работа №2**

по дисциплине: Технологии нейросетевых вычислений

вариант: Plant Segmentation

Выполнили: Миху Вадим

Чернова Анна

P34301

Преподаватель: Старобыховская Анастасия Александровна

Санкт-Петербург  
2024

## Задание

1. Выполнить Лабораторную работу 1
2. Согласовать способ оптимизации для вашей модели (см слайд 6)
3. Реализовать способ
  - а. Можно использовать функции и модули pyTorch
4. Получить метрики и графики обучения, инференса
5. Выполнить анализ и сравнение с исходной моделью
6. Получить оценки по точности, примеры ошибочных семплов, сделать выводы
7. Создать отчет (добавить графики лосса, точности и др.), прикрепить к заданию
8. Защититься на 12+ баллов

## Выполнение

### I. Модель

#### Исходный код модели

```
def create_unet_model(input_size=(IMG_HEIGHT, IMG_WIDTH, 3)):
    inputs = keras.layers.Input(input_size)

    c1 = keras.layers.Conv2D(64, (3, 3), activation='relu', padding='same')(inputs)
    c1 = keras.layers.Conv2D(64, (3, 3), activation='relu', padding='same')(c1)
    p1 = keras.layers.MaxPooling2D((2, 2))(c1)

    c2 = keras.layers.Conv2D(128, (3, 3), activation='relu', padding='same')(p1)
    c2 = keras.layers.Conv2D(128, (3, 3), activation='relu', padding='same')(c2)
    p2 = keras.layers.MaxPooling2D((2, 2))(c2)

    c3 = keras.layers.Conv2D(256, (3, 3), activation='relu', padding='same')(p2)
    c3 = keras.layers.Conv2D(256, (3, 3), activation='relu', padding='same')(c3)

    u1 = keras.layers.UpSampling2D((2, 2))(c3)
    u1 = keras.layers.concatenate([u1, c2])
    c4 = keras.layers.Conv2D(128, (3, 3), activation='relu', padding='same')(u1)
    c4 = keras.layers.Conv2D(128, (3, 3), activation='relu', padding='same')(c4)


    u2 = keras.layers.UpSampling2D((2, 2))(c4)
    u2 = keras.layers.concatenate([u2, c1])
    c5 = keras.layers.Conv2D(64, (3, 3), activation='relu', padding='same')(u2)
    c5 = keras.layers.Conv2D(64, (3, 3), activation='relu', padding='same')(c5)

    outputs = keras.layers.Conv2D(1, (1, 1), activation='sigmoid')(c5)
    model = keras.Model(inputs, outputs)
    return model
```

## II. Оптимизация

Метрики не обученной модели без оптимизации.

Layer (type)	Output Shape	Param #	Connected to
input_5 (InputLayer)	[(None, 256, 256, 3)]	0	[]
conv2d_44 (Conv2D)	(None, 256, 256, 64)	1792	['input_5[0][0]']
conv2d_45 (Conv2D)	(None, 256, 256, 64)	36928	['conv2d_44[0][0]']
max_pooling2d_8 (MaxPooling2D)	(None, 128, 128, 64)	0	['conv2d_45[0][0]']
conv2d_46 (Conv2D)	(None, 128, 128, 128)	73856	['max_pooling2d_8[0][0]']
conv2d_47 (Conv2D)	(None, 128, 128, 128)	147584	['conv2d_46[0][0]']
max_pooling2d_9 (MaxPooling2D)	(None, 64, 64, 128)	0	['conv2d_47[0][0]']
conv2d_48 (Conv2D)	(None, 64, 64, 256)	295168	['max_pooling2d_9[0][0]']
conv2d_49 (Conv2D)	(None, 64, 64, 256)	590080	['conv2d_48[0][0]']
up_sampling2d_8 (UpSampling2D)	(None, 128, 128, 256)	0	['conv2d_49[0][0]']
concatenate_8 (Concatenate)	(None, 128, 128, 384)	0	['up_sampling2d_8[0][0]', 'conv2d_47[0][0]']
conv2d_50 (Conv2D)	(None, 128, 128, 128)	442496	['concatenate_8[0][0]']
conv2d_51 (Conv2D)	(None, 128, 128, 128)	147584	['conv2d_50[0][0]']
up_sampling2d_9 (UpSampling2D)	(None, 256, 256, 128)	0	['conv2d_51[0][0]']
concatenate_9 (Concatenate)	(None, 256, 256, 192)	0	['up_sampling2d_9[0][0]', 'conv2d_45[0][0]']
conv2d_52 (Conv2D)	(None, 256, 256, 64)	110656	['concatenate_9[0][0]']
conv2d_53 (Conv2D)	(None, 256, 256, 64)	36928	['conv2d_52[0][0]']
conv2d_54 (Conv2D)	(None, 256, 256, 1)	65	['conv2d_53[0][0]']
Total params: 1883137 (7.18 MB)			
Trainable params: 1883137 (7.18 MB)			
Non-trainable params: 0 (0.00 Byte)			



Применим к модели `prune_low_magnitude` прунинг, после чего обучим ее до конца.

```
prune_low_magnitude = tfmot.sparsity.keras.prune_low_magnitude
pruning_schedule = tfmot.sparsity.keras.PolynomialDecay(
    initial_sparsity=0.2,
    final_sparsity=0.8,
    begin_step=0,
    end_step=1000
)

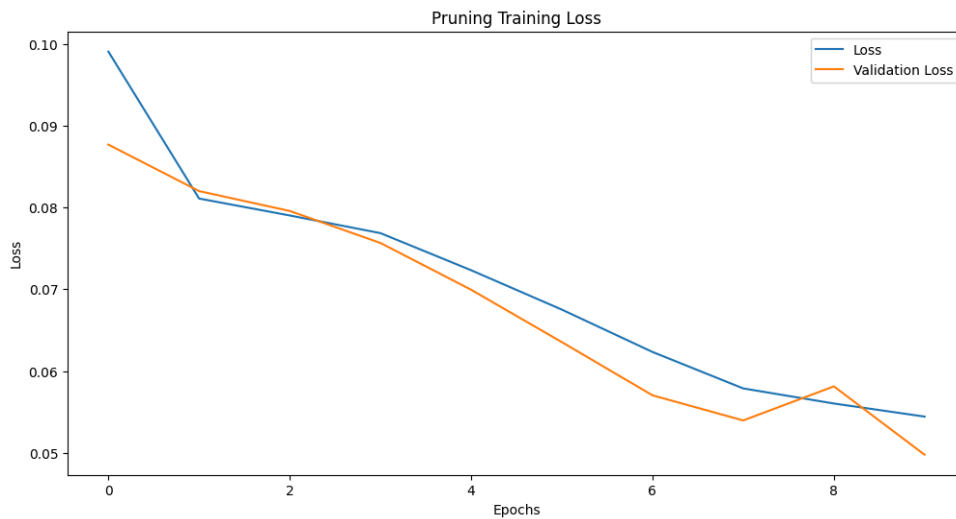
pruned_model = prune_low_magnitude(base_model, pruning_schedule)

pruned_model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['accuracy'])

callbacks = [
    tfmot.sparsity.keras.UpdatePruningStep(),
    tfmot.sparsity.keras.PruningSummaries(log_dir='./logs')
]
```

Layer (type)	Output Shape	Param #	Connected to
input_5 (InputLayer)	[(None, 256, 256, 3)]	0	[]
prune_low_magnitude_conv2d_44 (PruneLowMagnitude)	(None, 256, 256, 64)	3522	['input_5[0][0]']
prune_low_magnitude_conv2d_45 (PruneLowMagnitude)	(None, 256, 256, 64)	73794	['prune_low_magnitude_conv2d_44[0][0]']
prune_low_magnitude_max_pooling2d_8 (PruneLowMagnitude)	(None, 128, 128, 64)	1	['prune_low_magnitude_conv2d_45[0][0]']
prune_low_magnitude_conv2d_46 (PruneLowMagnitude)	(None, 128, 128, 128)	147586	['prune_low_magnitude_max_pooling2d_8[0][0]']
prune_low_magnitude_conv2d_47 (PruneLowMagnitude)	(None, 128, 128, 128)	295042	['prune_low_magnitude_conv2d_46[0][0]']
prune_low_magnitude_max_pooling2d_9 (PruneLowMagnitude)	(None, 64, 64, 128)	1	['prune_low_magnitude_conv2d_47[0][0]']
prune_low_magnitude_conv2d_48 (PruneLowMagnitude)	(None, 64, 64, 256)	590082	['prune_low_magnitude_max_pooling2d_9[0][0]']
prune_low_magnitude_conv2d_49 (PruneLowMagnitude)	(None, 64, 64, 256)	1179906	['prune_low_magnitude_conv2d_48[0][0]']
prune_low_magnitude_up_sampling2d_8 (PruneLowMagnitude)	(None, 128, 128, 256)	1	['prune_low_magnitude_conv2d_49[0][0]']
prune_low_magnitude_concatenate_8 (PruneLowMagnitude)	(None, 128, 128, 384)	1	['prune_low_magnitude_up_sampling2d_8[0][0]', 'prune_low_magnitude_conv2d_47[0][0]']
prune_low_magnitude_conv2d_50 (PruneLowMagnitude)	(None, 128, 128, 128)	884866	['prune_low_magnitude_concatenate_8[0][0]']
prune_low_magnitude_conv2d_51 (PruneLowMagnitude)	(None, 128, 128, 128)	295042	['prune_low_magnitude_conv2d_50[0][0]']
prune_low_magnitude_up_sampling2d_9 (PruneLowMagnitude)	(None, 256, 256, 128)	1	['prune_low_magnitude_conv2d_51[0][0]']
prune_low_magnitude_concatenate_9 (PruneLowMagnitude)	(None, 256, 256, 192)	1	['prune_low_magnitude_up_sampling2d_9[0][0]', 'prune_low_magnitude_conv2d_45[0][0]']
prune_low_magnitude_conv2d_52 (PruneLowMagnitude)	(None, 256, 256, 64)	221250	['prune_low_magnitude_concatenate_9[0][0]']
prune_low_magnitude_conv2d_53 (PruneLowMagnitude)	(None, 256, 256, 64)	73794	['prune_low_magnitude_conv2d_52[0][0]']
prune_low_magnitude_conv2d_54 (PruneLowMagnitude)	(None, 256, 256, 1)	131	['prune_low_magnitude_conv2d_53[0][0]']
=====			
Total params: 3765021 (14.36 MB)			
Trainable params: 1883137 (7.18 MB)			
Non-trainable params: 1881884 (7.18 MB)			

Прунинг применяется ко всем слоям модели. Ниже приведен график падения лосса при обучении.



### III. Анализ


Из метрик и графиков обучения можно сделать предположение о том, что дальнейшее обучение происходит эффективно, так как метрики улучшаются.

Произведем подсчет непустых нейронов модели, чтобы понять, какую часть из них занулил прунинг.


```
Number of non-null neurons in the base model: 1883137
Number of non-null neurons in the pruned model: 1385988
```

### IV. Сравнение

Предсказание оригинальной модели. Выбрана случайная картинка из тренировочных данных.



Предсказание модели с прунингом. Как можем наблюдать, разница на глаз неотличима.



## V. Вывод

Использование прунинга для оптимизации модели является хорошим решением. Небольшой процент прунинга фактически не имеет влияния